

表 1: MRAG-Bench 中 Baseline 解码与 Beam Search (MRAG_NUM_BEAMS = 5) 准确率对比。

指标	Baseline	Beam=5	Δ
Overall Accuracy	59.05	57.21	-1.84
Partial	64.23	60.98	-3.25
Others	64.17	64.17	0.00
Temporal	57.72	59.06	+1.34
Biological	55.88	55.88	0.00
Incomplete	29.41	30.39	+0.98
Obstruction	67.59	63.89	-3.70
Angle	59.63	56.21	-3.42
Scope	66.67	63.73	-2.94
Deformation	56.86	54.90	-1.96

Δ = Beam=5 - Baseline, 数值越大越好。

1 实验 2: MagicLens 在真实检索 RAG 图像上的表现

本实验在更贴近实际的设定下评估 MagicLens 重排能力: RAG 示例来自数据集提供的检索结果 (USE_GT=0), 而非 oracle GT 图像。实验配置为 MAX_RAG_IMAGES=5, LLAVA_NUM_BEAMS=1, 并在全部 1353 个测试样本上运行。

我们进一步统计了真实检索设定下每条样本进入流程的 `retrieved_images` 数量分布 (来自 E2 输出中的 `meta_rag_count`): 5 张占 92.46% (1251/1353), 1 张占 7.54% (102/1353)。

关键结论。

- E2 (MagicLens+Retrieved-RAG) 总体准确率为 51.74% (700/1353), 低于 E0 (59.05%) 与 E1 (60.16%)。
- 降幅最明显的场景是 *Partial*、*Angle*、*Obstruction* 和 *Temporal*。




图 1: `retrieved_images` 数量分布直方图 (E2 全量 1353 样本)。

- 在真实检索重排设定下, *Incomplete* 是唯一提升的场景。
- 模型输出格式稳定 (全部样本均为单字母 A/B/C/D), 因此性能下降主要来自检索质量与任务难度, 而非答案解析错误。
- Angle* + *Partial* + *Temporal* 的错误集中占比分别为 E0 51.09%、E1 50.28%、E2 54.36%, E2 的错误更集中于这三类场景。




图 2: E0 (GT-RAG Baseline)、E1 (MagicLens+GT) 与 E2 (MagicLens+Retrieved) 在各场景下的错误构成对比。高亮场景 (*Angle*、*Partial*、*Temporal*) 在三组中的错误占比分别为 51.09%、50.28%、54.36%。

表 2: 实验命名与结果总表: E0-E6 在 MRAG-Bench 各场景上的准确率 (%)。

Method	Overall	Perspective				Transformative				Others
		Angle	Partial	Scope	Occlusion	Temporal	Deformation	Incomplete	Biological	
E0: LLaVA+GT-RAG Baseline	59.05	59.63	64.23	66.67	67.59	57.72	56.86	29.41	55.88	64.17
E1: MagicLens+GT-RAG	60.16	61.49	65.45	66.67	69.44	58.39	57.84	30.39	55.88	65.00
E2: MagicLens+Retrieved-RAG	51.74	51.24	50.41	59.80	59.26	48.99	55.88	33.33	50.00	59.17
E3: LLaVA+Retrieved-RAG Baseline	-	-	-	-	-	-	-	-	-	-
E4: LLaVA+No-RAG	-	-	-	-	-	-	-	-	-	-
E5: MagicLens Pipeline (USE_GT=1, Rerank Off)	-	-	-	-	-	-	-	-	-	-
E6: MagicLens Pipeline (USE_GT=0, Rerank Off)	-	-	-	-	-	-	-	-	-	-

E0: `use_rag=True`, `use_retrieved_examples=False`; E1: `USE_GT=1` (MagicLens 对 `gt_images` 重排); E2: `USE_GT=0` (MagicLens 对 `retrieved_images` 重排); E3: LLaVA 仅用 `retrieved_images` (无 MagicLens); E4: `use_rag=False`; E5/E6: 与 E1/E2 同流程但关闭重排, 用于控制变量。