

南京师范大学

# 毕业设计(论文)

## (2026届)



题目: 基于混合检索器的多模态生成模型研究与实现

学院: 计算机与电子信息学院/人工智能学院

专业: 人工智能

姓名: 时子延

学号: 19220422

指导教师: 宋歌

南京师范大学教务处 制

## 摘 要

在以视觉为中心的多模态检索增强生成 (vision-centric mRAG) 任务中, 下游多模态模型能否正确作答, 往往首先受限于外部视觉证据是否被准确召回。与文本 RAG 主要补充事实知识不同, 本文关注的任务要求系统根据查询图像与问题文本, 从外部图像库中找到能够补足回答所需信息的候选证据图像; 因此, 检索目标不再是一般意义上的视觉相似图像, 而是对当前问题有帮助的图像证据。围绕这一检索瓶颈, 本文以 MRAG-Bench 为核心平台, 对其候选字段、视觉证据覆盖和场景分布进行再统计, 发现数据集给定候选与人工标注正例证据并不等价: 44.12% 的样本二者完全无重叠, 平均 GT 覆盖率仅为 22.78%。这一结果说明, 若不区分局部重排与真实全库检索, 容易混淆候选覆盖能力和候选排序能力。

基于上述分析, 本文将实验设计为局部重排、全库检索与查询侧扩展三个部分, 并将 E8 作为本文主要系统架构: 利用 Gemma 4 根据查询图像、题干与选项生成五条互补检索维度, 驱动 MagicLens 在完整图像库上分路召回, 再通过 RRF 列表融合得到最终证据集合, 并交由 LLaVA-OneVision 完成多选题终答。所有实验均固定下游 VLM 与提示模板, 使性能差异主要归因于检索与查询构造环节。全量 MRAG-Bench 测试结果表明, E8 在 1353 个样本上达到 56.32% 准确率, 是本文非 GT 全库检索路线中的最佳结果; 相较 MagicLens direct retrieval (E7) 提升 8.35 个百分点, 相较 CLIP corpus RAG (E3) 提升 5.91 个百分点。与此同时, 人工标注证据路线 E1/E5 仍保持约 60.16% 的参考上界, 说明查询侧扩展显著改善了真实全库检索效果。

除最终准确率外, 本文还引入前五候选重叠数 (Top-5 overlap, 指两种检索设置的前五候选中相同图像的数量)、首位一致率 (Top-1 match, 指两种设置的第一名候选是否一致)、逐样本胜负统计、高频重复命中分布与 E8/E9 样本级过程记录等分析指标。实验观察到, CLIP 与 MagicLens 在 67.2% 的样本上 Top-5 候选完全不重合, 说明二者具有显著不同的检索偏好; MagicLens 还存在 Top-1 “原型图吸附” 偏置, 部分高响应图像被大量不同查询重复命中。E8 的过程记录进一步显示, 多维检索产生的 25 个候选在 RRF 融合前平均保留 19.35 个唯一候选, 94.75% 的样本存在跨维重复命中, 说明多维查询确实形成了可融合的证据共识。E9 在保持同一检索侧框架、仅将终答器替换为 Gemma 4 E2B-it 后降至 38.95%, 说明最终 VLM 的多图证据整合能力同样是系统瓶颈。本文建立了包含 benchmark 复现、候选覆盖再分析、E0-E9 实验线组织、样本级过程记录、可视化图表和错误模式分析在内的统一评测方法。

**关键词:** 多模态检索增强生成; 混合检索; MRAG-Bench; MagicLens; 查询链编排

## Abstract

In vision-centric multimodal retrieval-augmented generation (mRAG), final answer quality is often bounded by whether the system can retrieve useful external visual evidence. Unlike text RAG, this task requires retrieving evidence images that help answer a question conditioned on both the query image and the question text. This thesis uses MRAG-Bench as the evaluation platform and re-analyzes its candidate fields, evidence coverage, and scenario distribution. The analysis shows that provided retrieved candidates and human-annotated ground-truth evidence are not equivalent: 44.12% of samples have no overlap, and the average GT coverage is only 22.78%. This motivates a clear separation between local reranking and full-corpus retrieval.

The experiments are organized into a reranking line, a corpus retrieval line, and a query-side extension line. The E8 pipeline is the main architecture: Gemma 4 generates five complementary retrieval dimensions from the query image, question, and choices; MagicLens performs per-dimension full-corpus retrieval; reciprocal rank fusion (RRF) produces the final evidence set; and a fixed LLaVA-OneVision model predicts the answer. On the full MRAG-Bench test split of 1,353 samples, E8 reaches 56.32% accuracy, the best non-GT full-corpus retrieval result in this work. It improves over MagicLens direct retrieval (E7) by 8.35 percentage points and over CLIP corpus RAG (E3) by 5.91 points, while settings using human-annotated evidence in E1/E5 still reach 60.16%.

Beyond accuracy, this thesis introduces Top-5 overlap, Top-1 match rate, per-sample win/loss statistics, repeated Top-1 hit analysis, and sample-level process records for E8/E9. CLIP and MagicLens return disjoint Top-5 candidates on 67.2% of samples, showing different retrieval preferences. MagicLens also exhibits a Top-1 prototype-attraction bias, where a small number of high-response images are repeatedly retrieved. E8 records show that five-dimensional retrieval keeps 19.35 unique candidates on average before fusion and that 94.75% of samples contain cross-dimension repeated hits. E9 keeps the same retrieval side but replaces the answerer with Gemma 4 E2B-it, dropping to 38.95%, which shows that multi-image evidence integration by the final VLM is also a bottleneck. Overall, this work provides a reproducible evaluation framework covering benchmark reproduction, E0–E9 experiments, sample-level records, visualization, and error-mode analysis.

**Key words:** multimodal RAG; hybrid retrieval; MRAG-Bench; MagicLens; query planning

# 目录

|                                                |    |
|------------------------------------------------|----|
| 摘 要                                            | I  |
| Abstract                                       | II |
| 1 绪论                                           | 1  |
| 1.1 研究背景及研究意义                                  | 1  |
| 1.1.1 从 LLM 到多模态检索增强                           | 1  |
| 1.1.2 多模态生成模型的幻觉与知识冻结问题                        | 1  |
| 1.1.3 检索增强生成与 mRAG 范式的发展                       | 2  |
| 1.1.4 本文的目的及研究意义                               | 2  |
| 1.2 国内外研究现状                                    | 3  |
| 1.2.1 多模态 RAG 框架与评测基准                          | 3  |
| 1.2.2 多模态问答 (VQA) 任务的发展脉络                      | 3  |
| 1.2.3 通用多模态检索模型                                | 3  |
| 1.2.4 多模态生成、训练与增强方法                            | 4  |
| 1.3 研究内容                                       | 4  |
| 1.3.1 Benchmark 再解构与评测前分析                      | 4  |
| 1.3.2 混合检索方法设计与实现                              | 5  |
| 1.3.3 统一评测与可解释分析                               | 5  |
| 1.4 论文结构                                       | 5  |
| 2 相关技术与理论基础                                    | 6  |
| 2.1 基线方法与改进管线                                  | 6  |
| 2.1.1 基线检索器                                    | 6  |
| 2.1.2 本文混合检索管线设计                               | 7  |
| 2.1.3 Pipeline LLM (管线语言模型) 与查询链编排             | 9  |
| 3 实验设计                                         | 10 |
| 3.1 数据集与候选覆盖分析                                 | 10 |
| 3.2 评价指标与实验设置                                  | 10 |
| 3.3 实验线设计                                      | 12 |
| 3.4 面向多维查询与融合式终答的实验管线 (E8)                     | 13 |
| 3.4.1 实验流程与结果记录                                | 13 |
| 3.4.2 与既有实验相比的方法扩展                             | 14 |
| 3.4.3 样例分析: MRAG-Bench 样本 <code>qs_id=0</code> | 14 |



|          |                                      |           |
|----------|--------------------------------------|-----------|
| 3.4.4    | 全数据集运行结果 . . . . .                   | 15        |
| <b>4</b> | <b>实验结果分析</b>                        | <b>18</b> |
| 4.1      | 本章概述 . . . . .                       | 18        |
| 4.2      | 整体结果与控制实验 . . . . .                  | 18        |
| 4.3      | 实验命名与结果总表 . . . . .                  | 18        |
| 4.4      | Corpus 线结果分析 . . . . .               | 20        |
| 4.5      | CLIP 与 MagicLens 检索差异深入分析 . . . . .  | 22        |
| 4.5.1    | 检索集合差异 . . . . .                     | 22        |
| 4.5.2    | 分场景检索差异 . . . . .                    | 23        |
| 4.5.3    | Top-1 高频重复偏置 . . . . .               | 25        |
| 4.6      | 时间代价与效率目标 . . . . .                  | 25        |
| 4.7      | 扩展对比实验 . . . . .                     | 26        |
| 4.7.1    | 指令检索器 MagicLens 与 CLIP 的对比 . . . . . | 26        |
| 4.7.2    | 下游生成器 LLaVA 与 Gemma 4 的对比 . . . . .  | 27        |
| 4.7.3    | RRF 融合与候选结构 . . . . .                | 28        |
| 4.7.4    | 检索结果可视化与案例展示 . . . . .               | 28        |
| 4.8      | 消融实验 . . . . .                       | 28        |
| 4.8.1    | 查询重写模块的作用分析 . . . . .                | 29        |
| 4.8.2    | 多维查询相较单维查询的收益分析 . . . . .            | 29        |
| <b>5</b> | <b>总结</b>                            | <b>31</b> |
| 5.1      | 总结 . . . . .                         | 31        |
|          | 参考文献 . . . . .                       | 31        |

## 第1章 绪论

### 1.1 研究背景及研究意义

#### 1.1.1 从 LLM 到多模态检索增强

以 Transformer 为基础的大规模语言模型 (LLM) 显著提升了自然语言理解、推理和生成任务的能力<sup>1;2</sup>。这类模型通过大规模预训练和指令微调获得了丰富的参数化知识,但其知识边界仍受训练语料、时间截断和模型参数容量限制。在面向专业领域、实时事件或长尾对象的应用中,仅依赖模型内部记忆往往难以保证回答的可验证性。

检索增强生成 (Retrieval-Augmented Generation, RAG) 通过在生成前显式访问外部知识库,将用户输入与检索证据共同交给生成模型,从而缓解参数化知识的时效性缺陷与证据不可追溯问题<sup>3;4</sup>。这一范式把模型回答从完全依赖内部参数,转向依赖可检索、可更新、可审计的外部证据。对于开放域问答、专业文档问答和事实核查任务, RAG 的关键价值不只在提高准确率,也在于让系统能够解释回答依据。

多模态大模型的发展使外部证据从文本扩展到图像、表格、文档和视频等模态,多模态检索增强生成 (Multimodal RAG, mRAG) 由此成为重要研究方向<sup>5;6</sup>。在多模态任务中,证据对象不再只是“相关文本段落”,而可能是某个角度的图像、某一时间状态的视觉记录,或能够补足结构信息的外部图片。检索器需要判断的也不只是语义相关性,而是证据是否能够支撑下游模型完成当前问题。

本文关注的视觉中心型多模态检索增强生成 (vision-centric mRAG, 指以“是否召回到有用视觉证据”为核心约束的 mRAG 任务) 更进一步:很多问题不是让模型直接看一张图回答,而是要求系统先从外部图像库中找回辅助证据,再由下游视觉语言模型给出答案。此时,外部视觉证据是否被正确召回,会比生成模型本身的语言能力更直接地限制最终结果。换言之, vision-centric mRAG 的核心瓶颈并非单纯“模型是否会生成”,而是“系统是否找到了值得生成模型参考的候选证据图像”。

#### 1.1.2 多模态生成模型的幻觉与知识冻结问题

多模态大模型虽然能够同时处理图像与文本输入,但知识冻结和幻觉问题并未消失。知识冻结指模型训练语料存在时间边界,面对新知识、领域私有知识和长尾对象时容易给出过时或不可验证的回答<sup>4</sup>。幻觉则指模型在证据不足或证据冲突时生成表面合理但事实错误的内容。在多模态问答中,幻觉不仅表现为文本事实错误,还会具体表现为对象错配、属性错配、关系错配、时间状态错配、视角错配以及结构信息缺失导致的误判<sup>7</sup>。

这些错误形式与本文实验中的场景划分具有直接关系。例如, *Angle* 与 *Partial* 场景常涉及视角和局部可见性问题, *Temporal* 场景要求系统区分时间状态变化, *Incomplete* 场景则要求找到能够补全缺失结构的视觉证据。若检索器返回的候选证据图像本身偏

离任务需求，下游视觉语言模型即使具备较强的单图理解能力，也可能被噪声证据引导到错误答案。因此，在 mRAG 系统中，检索质量不是生成前的辅助环节，而是决定证据边界和回答上限的关键因素。

### 1.1.3 检索增强生成与 mRAG 范式的发展

RAG 与 mRAG 的系统形态已经从简单的“检索后拼接上下文”，发展为同时涉及检索规划、模态选择、跨模态对齐、证据排序和生成控制的复杂流程<sup>5,6</sup>。与此同时，智能体 (Agent, 指可自主调用工具并执行多步任务的系统组件)、模型上下文协议 (MCP, Model Context Protocol, 用于统一模型与外部工具/数据源交互的协议) 和技能模块 (Skills, 指可复用的任务能力封装) 等工程机制也推动了外部工具和外部知识协同使用的系统落地<sup>8-11</sup>。这些发展说明，检索器已经不只是模型前端的相似度搜索模块，而是连接任务意图、外部证据和最终生成的重要接口。

在图像证据参与的任务中，传统最近邻检索不能完全满足需求。本文真正要处理的不是通用图像检索 (generic image retrieval)，而是问题条件证据检索 (question-conditioned evidence retrieval)。在这类任务中，查询图像既不是最终证据，也不是唯一检索条件；问题文本决定了系统究竟需要补足哪一种视觉信息，因此检索目标 (retrieval target) 从视觉相似图像 (visually similar image) 转变为对答案有用的证据图像 (answer-useful evidence image)。基于这一判断，本文选择 CLIP 与 MagicLens 形成代表性的能力对比：前者提供稳定的视觉语义粗召回，后者通过开放式指令建模图像间关系，从而更接近问题导向证据排序的需求<sup>12,13</sup>。

### 1.1.4 本文的目的及研究意义

本文的核心目标不是追求某一次实验设置下的最高准确率，而是澄清 vision-centric mRAG 中检索器收益的来源、边界和失败机制。围绕这一目标，本文提出并验证一种面向问题导向证据召回的混合检索方法，并将基准数据集再分析 (benchmark 再分析)、实验变量拆分、系统实现、错误模式分析和推理期扩展组织为完整研究闭环。具体而言，本文试图回答以下问题：

1. 在多模态问答任务中，检索器的收益究竟来自局部重排还是完整图像库的粗召回？
2. MagicLens 这类指令感知检索模型 (instruction-aware 检索模型，指检索时显式利用自然语言指令约束关系匹配)，是否能够稳定优于 CLIP 式相似度检索？
3. 当检索结果没有带来整体增益时，问题究竟出在候选覆盖、排序机制，还是查询表示 (query 表征) 本身？
4. 在不改动检索器本体参数的前提下，多维查询与结果融合等查询侧扩展，能否为全库检索带来可解释、可复现的收益？

上述研究有助于把 mRAG 系统中的检索问题从“模块接入”推进到“证据召回机制分析”。在更广泛的应用中，具身智能、脑机接口和类脑记忆系统都需要长期外部记

忆与可验证证据访问，本文形成的评测拆分、候选覆盖分析和检索偏差诊断方法，也可为此类场景提供参考<sup>14-17</sup>。

## 1.2 国内外研究现状

### 1.2.1 多模态 RAG 框架与评测基准

当前多模态 RAG 研究主要围绕系统框架、知识组织方式和评测基准展开<sup>5,6</sup>。一类工作关注如何让模型在文本、图像、表格和文档之间整合证据；另一类工作关注如何用评测基准（benchmark）度量检索阶段与生成阶段的耦合误差。现有视觉问答与知识增强基准如 OK-VQA、A-OKVQA、WebQA、InfoSeek 等推动了外部知识研究，但许多任务仍以文本知识为中心，对“视觉证据本身是否被正确召回”的刻画不够充分。

现有 benchmark 往往同时耦合检索器、生成器、提示模板和外部知识组织方式，因而不容易单独判断检索阶段的能力边界。MRAG-Bench 的价值在于，它明确面向 vision-centric mRAG 场景构建，要求系统在很多题目上借助图像证据才能稳定回答<sup>18</sup>。本文正是利用这一特点，将 MRAG-Bench 重构为“固定下游模型，仅比较检索器”的研究平台，并进一步区分局部重排与真实全库检索两类能力。

### 1.2.2 多模态问答（VQA）任务的发展脉络

从任务定义上看，本文所研究的问题仍然属于多模态问答（VQA）的延伸形态。传统 VQA 更关注给定图像，模型能否理解图像内容并回答自然语言问题；而本文所处的 vision-centric mRAG 场景，则进一步要求系统在回答前先从外部图像库中找回有帮助的视觉证据，再将这些证据交给下游多模态模型完成最终作答。也就是说，本文研究的不是纯单图 VQA，而是带外部视觉证据检索的 VQA。

VQA 的研究主线大致经历了三个阶段。第一阶段聚焦单张图像上的目标识别、属性理解与关系推断，核心问题是模型能否理解给定图像；第二阶段引入常识知识、开放域知识与多跳推理，使问题不再只依赖图像局部内容；第三阶段走向多模态大模型与检索增强系统，把图像理解和外部证据调用放在同一流程中。在这一演进过程中，评价重点从对象识别正确率扩展到证据利用能力、跨模态对齐能力和多步推理能力。

本文并不主要研究“模型是否看懂单张图像”，而是研究“系统是否能在外部图像库中找到补足回答所需证据的图像”。从国内外研究现状看，VQA、知识增强 VQA 与多模态检索增强系统已经形成较成熟的 benchmark 和模型生态，但专门面向视觉证据检索质量本身的分析型工作仍相对有限。本文因此将检索器召回内容、证据有效性和失败模式作为主要分析对象，而不是只比较最终问答准确率。

### 1.2.3 通用多模态检索模型

在通用多模态检索领域，CLIP 及其后续工作构成了主流基础<sup>12</sup>。通过对比学习，CLIP 将图像与文本映射到共享向量空间，使图文检索成为可能。随后，ALIGN、FG-CLIP、Long-CLIP 和 EI-CLIP 等工作分别从数据规模、细粒度对齐、长文本支持与实

体感知建模等角度进行改进<sup>19-22</sup>。

对于本文而言，CLIP 不只是相关工作的背景模型，还承担了非常具体的实验角色。本文在全库检索实验（corpus retrieval）中选用 openai/clip-vit-base-patch32 作为第一阶段粗召回器，原因主要有三点：第一，它是开放可复现、实现成熟且社区广泛使用的通用视觉表征模型，适合作为稳定基线（baseline）；第二，它的图像编码接口简单，便于对完整图像库做离线向量化和缓存，能够较低成本地支撑全库检索实验；第三，CLIP 更强调视觉外观相似与语义近邻匹配，这恰好适合担任“先保住视觉邻域”的粗召回器，从而与后续 MagicLens 的关系感知能力形成互补。

CLIP 与 MagicLens 的差异并不是简单的“模型先进程度”差异，而是优化目标和归纳偏好的差异。CLIP 更偏向共享嵌入空间中的视觉语义相似，适合作为稳定粗召回器；MagicLens 则利用开放式文本指令学习图像间关系，检索目标不再局限于“最像的图”，而是“满足给定关系的图像”<sup>13</sup>。这一差异与 mRAG 中“寻找问题所需证据”的需求高度相关，因此成为本文构建混合检索框架和解释实验结果的基础。

#### 1.2.4 多模态生成、训练与增强方法

除检索器本身外，多模态生成模型和扩散模型也为检索增强研究提供了训练与增强路径<sup>23-25</sup>。扩散模型能够合成具备可控属性与结构变化的图像样本，适合构造困难负样本或长尾场景数据；ControlNet 与 StableRep 等工作则说明，生成模型不仅可以服务于内容生成，也可以反向支撑检索器训练与表征学习<sup>26;27</sup>。

不过，本文不展开生成模型训练、检索器再训练或端到端联合优化，而聚焦推理期检索器设计与评测（inference-time retriever design and evaluation）。这样的边界使本文能够更清楚地控制变量：在固定下游 VLM 的条件下，只分析检索器、查询构造和证据融合对 vision-centric mRAG 的影响。

### 1.3 研究内容

本文围绕 vision-centric mRAG 检索瓶颈展开，研究内容按“数据与评测再解构—混合检索方法设计—统一实验与可解释分析”三部分组织。

#### 1.3.1 Benchmark 再解构与评测前分析

本文首先完成 MRAG-Bench 的数据字段解析、候选构成复现、场景分布统计和 GT/候选重叠分析。为避免把 benchmark 自带候选集合上的局部重排误认为真实全库检索能力，本文专门统计 gt\_images 与 retrieved\_images 的交集、覆盖率和零重叠比例，并据此将后续实验拆分为重排实验线（rerank line）与全库检索实验线（corpus line）。该部分工作形成了本文实验设计的前置依据：只有先区分候选覆盖问题与候选排序问题，才能解释不同检索器的真实收益来源。

### 1.3.2 混合检索方法设计与实现

针对 CLIP 与 MagicLens 的能力差异,本文设计并实现了 CLIP 粗召回、MagicLens 关系感知重排、MagicLens 直接检索 (direct retrieval)、查询重写 (query rewriting)、多维查询生成和列表融合等模块化组件。CLIP 用于提供稳定且可扩展的视觉语义候选覆盖, MagicLens 用于分析开放式指令下的关系检索能力; E8 进一步在不更新检索器参数的前提下,通过多维查询规划和融合式终答探索推理期扩展。本文方法的重点不是堆叠现成模型,而是围绕“视觉近邻召回”和“问题导向证据排序”的功能分工建立可对照的系统结构。

### 1.3.3 统一评测与可解释分析

本文构建统一评测与分析流程,组织 E0-E10 多条实验线,并在固定下游 VLM、提示模板和结果抽取逻辑的前提下比较不同检索策略与终答生成器。除整体准确率 (overall accuracy) 与分场景准确率 (scenario accuracy) 外,本文引入前五候选重叠数 (Top-5 overlap, 指两种检索设置的前五候选中相同图像的数量)、首位一致率 (Top-1 match, 指两种检索设置的第一名候选是否一致)、逐样本胜负统计、高频重复命中分布和样本级过程记录,用于定位检索器偏好差异、候选覆盖缺陷、原型图吸附以及多图证据利用失败等模式。论文中的主要图表均由统一脚本生成,使 benchmark 复现、结果统计和正文分析能够相互对应。

## 1.4 论文结构

本文共分为五章。第 1 章为绪论,介绍研究背景、研究意义、国内外研究现状、本文研究内容及论文结构;第 2 章介绍相关技术与理论基础,给出任务形式化定义、基线检索器、混合检索框架以及多维查询与融合方法;第 3 章介绍实验设计,包括数据集与候选覆盖分析、评价指标、实验线设计、E8 多维查询方法、样例分析与可视化过程;第 4 章介绍实验结果分析,包括整体结果、分场景分析、检索差异诊断、扩展对比实验与消融实验;第 5 章对全文进行总结。

## 第2章 相关技术与理论基础

### 2.1 基线方法与改进管线

本章介绍本文所使用的检索器、混合框架和查询侧扩展方法。为保证后续实验解释清楚，本章首先给出任务形式化定义，再分别说明 CLIP、MagicLens、混合检索框架以及 E8 的多维查询与列表融合策略。

本文研究的任务可以形式化为：给定查询图像  $x_q$  和问题文本  $q$ ，检索器需要从候选图像库中返回一个 Top- $K$  图像集合  $I = \{i_1, \dots, i_K\}$ ，随后由视觉语言模型  $M$  基于  $(x_q, q, I)$  输出最终答案  $\hat{y}$ 。这里的检索输出不是最终答案，而是辅助下游 VLM 作答的候选证据图像集合；本文优化对象是检索阶段（retrieval stage）与查询构造阶段（query construction stage），而不是答案生成阶段（answer generation stage）。若记检索器为  $R$ ，则整个流程可以表示为

$$I = R(x_q, q), \quad \hat{y} = M(x_q, q, I). \quad (2.1)$$

对于该任务，本文认为存在四个核心挑战。第一，查询图像与真正有用的候选证据图像之间，可能不是简单外观相似关系，而是视角、时间、结构缺失或语义补充关系。第二，局部重排与全库检索混在一起时，实验结果很难解释，必须拆分不同能力。第三，检索质量不仅体现在最终正确率上，还体现在候选集合结构与错误模式上。第四，若方法最终要服务于真实系统部署，就不能只停留在离线评测层面，还需要记录推理时延、资源占用和中间过程。

#### 2.1.1 基线检索器


本文选择 CLIP 与 MagicLens 作为核心检索器，并非为了穷尽所有最新模型，而是为了构建具有代表性的能力对比。CLIP 代表稳定、通用、可扩展的视觉语义粗召回；MagicLens 代表指令条件关系检索（instruction-conditioned relation retrieval，即在查询图像与文本指令共同条件下检索满足关系约束的图像）。二者的差异有助于分析 vision-centric mRAG 中“视觉近邻”和“问题有用证据”之间的偏离。

**基于 CLIP 的通用检索器。**CLIP 在本文中承担的是稳健粗召回器角色，它擅长在大规模图像库中快速找到视觉近邻。MagicLens 则更强调开放式指令驱动的关系检索能力，适合承担更贴近任务语义的候选重排模块。也正因为这两种模型的能力边界不同，本文才采用混合路线而不是单一模型路线。

**基于 MagicLens 的通用指令检索器。**本文采用的总体思路是：先通过 E0-E7 分离人工标注证据、局部重排与完整 corpus 检索三类情形，从而判断系统瓶颈究竟位于证据质量、候选组织还是全库召回；在此基础上，再将 E8 作为本文主要方法展开分析。



与直接把原始问题送入检索器的做法不同，E8 先由 Gemma 4 在查询图像、题干与选项的共同条件下生成五条互补检索维度，再由 MagicLens 按维度分别召回候选，并用 RRF 融合得到最终 Top-5 证据；随后，Gemma 4 为查询图和候选图生成辅助描述，最后由下游多模态 VQA 模型 LLaVA-OneVision 输出多选答案。为便于说明这一方法如何从问题理解逐步过渡到证据组织与终答生成，图 2.1 对整条处理链路作了整体展示。



**图 2.1 E8 模型流程介绍图。**上半部分展示 question 图像与选项如何经 Gemma 4 多维查询重写器生成五条检索指令，并由 MagicLens 在每个维度上返回 Top-5 结果；右侧的  $5 \times 5$  图像网格对应五个维度的分路检索结果。中部通过 Reciprocal Rank Fusion (RRF) 将多路结果统一融合为 Top-5 候选集。下半部分展示 Gemma 4 证据图描述器如何把查询图与候选图转化为最终多模态 VQA 提示词，随后 LLaVA-OneVision 输出结构化答案；右下角雷达图给出该管线在全数据集不同场景维度上的评测表现。

### 2.1.2 本文混合检索管线设计

**基于混合检索器的查询链设计。**从系统视角看，RAG 负责把外部知识引入生成过程，mRAG 则把这种知识扩展到图像、视频等多种模态。基座多模态模型负责在给定视觉条件下生成答案；检索增强系统则负责根据查询图像与问题文本构造检索需求、匹配候选证据图像，并以稳定的输入格式调用下游模型。本文的混合管线围绕这一分工设计。

在本文后续的方法框架里，管线语言模型 (pipeline LLM) 不只承担“调用一次模型回答问题”的角色，还承担查询分析、问题改写与推理链补充的作用。尤其是思维链机制 (CoT, Chain-of-Thought)，可以帮助系统把原始问题拆成更适合检索的中间语义表示，这一点对后续的问题到 query 的映射非常关键。



CLIP 路线将 query image 编码为视觉向量，与完整 corpus 中图像向量进行相似度计算，并返回 Top- $K$  候选<sup>12</sup>。该方法的优点是鲁棒、工程实现成熟、在大规模图像库中粗召回效率较高，因此适合作为真实系统中的第一阶段召回器。本文中的 E3 即对应“CLIP 直接从完整 corpus 召回 Top-5 候选”的 baseline。

MagicLens 与 CLIP 的差异在于，其 query 侧并不只依赖 query image，而是进一步融合开放式文本指令，使模型倾向于捕捉图像间的关系结构，而非仅仅寻找视觉邻居<sup>13</sup>。在本文中，MagicLens 被放置在两个位置上：

1. 作为重排器，对已有候选集进行 rerank，对应 E1、E2 和 E6；
2. 作为 direct retriever，直接从完整 corpus 中召回 Top-5，对应 E7。

通过这种设计，本文能够区分“MagicLens 在排序阶段是否有效”和“MagicLens 作为独立召回器是否稳定”这两个不同问题。更重要的是，该方法明确了 CLIP 与 MagicLens 在混合框架中的职责划分：前者负责稳定、可扩展的候选覆盖，后者负责更贴近问题语义的关系感知排序。若后续结果显示重排没有带来稳定收益，也能够进一步判断问题出在候选覆盖不足、排序目标不匹配，还是查询指令未能约束实例级视觉信息。

**基于 Gemma 4 的多维度查询重写。**本文的方法不将用户问题直接原样送入检索器，而是强调从“问题到检索语句”的中间转换（‘Question -> query’）。原因在于，原始问题往往更接近生成任务语言，而不一定是最适合检索的表达形式。对于 mRAG 来说，真正需要的是能够表达“当前任务到底要找什么证据”的 query。

因此，本文在 pipeline LLM 中加入查询重写模块。该模块通过问题理解、关键词抽取、关系补全与 CoT 推理，把原始 question 改写成更适合图像检索的 query 表达，并作为后续多维指令生成与分路召回的输入基础。

单一开放式英文指令虽然能把自然语言意图接入 MagicLens，但在全库检索条件下容易与查询图像的实例级约束脱节，排序结果也更容易被少数高响应模式牵引。为在不改动检索器参数的前提下扩展查询侧表达，本文实现“多检索维度—分路召回—列表融合”的链路：先用多模态模型在查询图像与题干共同条件下生成  $N$  条互补的短英文检索句，再令 MagicLens 在每条句子上各执行一次语料库排序，最后用融合算子把多路 Top- $K$  结果压缩为固定长度的候选集合并送入下游视觉语言模型。

维度规划器采用 Gemma 4 E2B-it (google/gemma-4-E2B-it)。该模型属于指令式多模态小体量变体，能够在查询图像与“题干 + 选项”共同条件下生成结构化检索维度。E8 全量实验采用结构化 JSON 提示：模型输出恰好  $N = 5$  个 dimensions，每个维度包含不超过约三十个词的英文检索 query 以及不超过约二十五个词的简短 rationale。解码采用确定性设置，以降低维度文本漂移；生成结果经 JSON 解析后写入实验记录，并用于后续 MagicLens 检索。

**查询后处理与结果聚合方法。**给定第  $j$  条指令文本  $t_j$  与查询图像  $x_q$ ，MagicLens 以  $(x_q, t_j)$  编码查询侧表征，在外部语料库向量上计算相似度并得到各自的 Top- $K_{\text{dim}}$  列表。多路列表若直接拼接，容易放大某一路检索中的偶然尖峰，也会造成候选证据冗余。因此，本文将多路结果送入融合模块：实现上支持倒数排名和（RRF）、分数求和与投票式策略等融合算子，将多份排序信号合并为长度  $K_{\text{final}}$  的候选序列，以抑制单路排序偏差并在不同语义维度之间折中。融合得到的图像路径与查询图像一起，按与 corpus 线实验相同的提示模板与选项抽取流程输入 LLaVA-OneVision，使该流程在“固定下游模型、更动检索与查询构造”的意义上可与 E0-E7 结果对照。

与上述 Gemma 4 分支并列，维度文本亦可通过仅消费题干的接口大模型或本地纯文本生成模型获得；二者不读取查询图像，部署成本较低，但无法利用画面中的细粒度线索拆分检索需求。三类后端在同一脚本入口中以参数切换，便于在控制硬件条件的前提下比较“文本规划”和“图文协同规划”对 MagicLens 召回行为的影响。与上述“多维指令—分路召回—结果融合”对应的 E8 实验流程已在统一脚本中实现，并输出逐样本过程记录、分场景统计与可视化结果。

**生成器的选择：LLaVA vs Gemma 4。**在生成器选择上，本文采用 LLaVA 作为当前实验主线中的答案生成器（用于 E0-E7 的可比实验），并将 Gemma 4 主要用于查询链中的维度规划与查询重写模块，以发挥其多模态指令理解优势。该策略保证了“检索器变化可控、生成器变量稳定”，也使 LLaVA 与 Gemma 4 作为终答生成器的系统对比能够在同一框架下展开。

### 2.1.3 Pipeline LLM（管线语言模型）与查询链编排

在本文的方法框架中，pipeline LLM 承担查询分析、问题改写与 CoT 式中间推理，用于把自然语言问题显式映射为更利于检索的中间表示，并驱动“多维度指令—分路召回—结果融合”的执行顺序。受算力、时间与课题边界限制，本文重点放在**推理期（inference-time）**的查询侧扩展（query-side expansion）与检索器侧对比（retriever-side comparison），不展开检索器参数更新（retriever parameter update）或端到端联合训练（end-to-end joint training）。

从工程实现上看，pipeline 中可调用的模型既可以是接口式大模型，也可以是本地部署的多模态模型（如 Gemma 4 用于维度规划），其差异主要体现在部署成本、时延与可复现性，但不改变本文以“固定下游 VLM、以检索与查询构造为唯一变量”的评测原则。

## 第3章 实验设计

### 3.1 数据集与候选覆盖分析

本章围绕 MRAG-Bench 展开实验设计。章节组织遵循“先解释 benchmark 结构，再定义指标与实验线，最后说明 E8 多维查询管线和样例可视化”的顺序。这样安排的原因是：本文的主要发现并非来自单一准确率数字，而来自对候选覆盖、局部重排、全库检索和查询侧扩展过程的分解设计。

本文使用 MRAG-Bench 作为核心评测数据集。该数据集包含 1353 个测试样本和 16130 张图像，覆盖 *Angle*、*Partial*、*Scope*、*Occlusion/Obstruction*、*Temporal*、*Deformation*、*Incomplete*、*Biological* 与 *Others* 等九类典型视觉难点<sup>18</sup>。

MRAG-Bench 不是普通单图 VQA 数据集，而是带外部视觉证据的多选 VQA benchmark。每个样本至少包含以下几部分信息：输入图像 `image`、问题文本 `question`、四个候选答案 `A/B/C/D`、标准答案 `answer/answer_choice`、人工标注的正例证据图像集合 `gt_images`，以及数据集额外给出的候选检索图集合 `retrieved_images`。这意味着它天然同时包含问答任务和检索任务两层结构。

在 MRAG-Bench 原始评测脚本里，下游模型接收到的输入形式并不是单独的一张查询图像（query image），而是“第 1 张图为输入图像，后若干张图为辅助证据图像”的多图输入形式。若不开启 RAG，则模型只看到输入图像；若开启 RAG，则模型会看到输入图像与额外证据图像，并在统一提示词下输出四选一答案。这一点可以从 MRAG-Bench 的官方数据加载器（`dataloader`）中直接看到：当 `use_rag=False` 时，`image_files=[image]`；当 `use_rag=True` 时，`image_files=[image]+gt_images`，若进一步指定 `use_retrieved_examples=True`，则证据部分改为 `retrieved_images`。

因此，`gt_images` 与 `retrieved_images` 的语义并不相同。前者是人工标注的正例证据，可作为评估系统在已知有效证据条件下表现的参考；后者则是数据集作者提供的一组检索候选，作用更接近已有检索器返回的外部图像。二者并非一一对应，也不是同一批图像的重命名。本文专门统计二者的重叠关系，目的正是避免把“在给定候选上做 rerank”误写成“真实图像库上的检索能力”。

本文首先对 `gt_images` 与 `retrieved_images` 两类字段进行了再统计。结果发现：在 44.12% 的样本中，两者完全无重叠，平均 GT 覆盖率仅为 22.78%。这一发现意味着，若不先区分候选覆盖问题与候选排序问题，则对检索器优劣的判断可能被 benchmark 自带候选集合所掩盖。基于这一发现，本文后续实验不把所有结果混在同一条线上比较，而是明确拆分为局部重排线和全库检索线。

### 3.2 评价指标与实验设置

为了尽量将性能差异归因于检索器本身，本文固定下游视觉语言模型与提示模板，仅改变图像检索策略。评价指标包括：

表 3.1 MRAG-Bench 原始字段数量与实际进入模型的候选数对照。

| Source              | 1           | 5              | Avg. |
|---------------------|-------------|----------------|------|
| GT raw              | 102 (7.54%) | 1251 (92.46%)  | 4.70 |
| Retrieved raw       | 0 (0.00%)   | 1353 (100.00%) | 5.00 |
| Retrieved effective | 102 (7.54%) | 1251 (92.46%)  | 4.70 |




图 3.1 MRAG-Bench 的候选结构与覆盖缺口综合分析。左上图显式标出候选数量与场景之间的关系：按本文使用的 dataloader 规则，*Incomplete* 场景的 102 个样本只保留 1 张证据图，其余场景均保留 5 张证据图；右上图统计各场景对零重叠样本的贡献，可见 coverage gap 主要来自 *Partial*、*Angle*、*Incomplete* 和 *Temporal*；左下图展示各场景 GT 召回率与零重叠比例；右下图进一步给出每个样本中 GT 集合与 retrieved 集合的交集规模分布。

1. **整体准确率 (Overall Accuracy)**: 最终多选题正确率;
2. **分场景准确率 (Scenario Accuracy)**: 九类细分场景的分项准确率;
3. **前五候选重叠数 (Top-5 Overlap)**: 不同检索器召回集合的交集规模, 用于观察二者是否进入同一视觉证据邻域;
4. **首位一致率 (Top-1 Match Rate)**: 不同检索器 Top-1 是否一致, 用于检测两类检索器是否存在共识中心;
5. **逐样本胜负统计**: 当两种检索器产生不同结果时, 比较谁最终答对更多样本。

此外, 本文还统计高频重复命中的 Top-1 图像分布, 用于刻画原型吸附偏置(prototype-attraction bias, 即少数高响应图像是否被大量不同查询反复命中)。这些指标的目不是替代最终准确率, 而是解释准确率背后的候选结构与失败机制。

### 3.3 实验线设计

基于前述候选覆盖分析, 本文将实验拆分为两条主线:

1. **重排实验线 (Rerank line)**: 在固定候选集上分析 MagicLens 是否能够改善排序;
2. **全库检索实验线 (Corpus line)**: 从完整图像库中进行粗召回, 再分析召回与重排的各自贡献。

本文按 *Control*、*Rerank* 与 *Corpus* 三类轨道组织实验, 而不是直接按 E0-E8 顺序罗列。这样做可以分离不同能力因素: *Control* 用于观察无外部证据或人工标注证据条件下的上下界; *Rerank* 用于分析给定候选集合内的排序能力; *Corpus* 用于评估从完整图像库中自行召回候选证据的真实能力。已完成或具备脚本支持的代表性实验包括:

- E0: LLaVA + GT-RAG baseline, 用于给出较高上界;
- E1: 在 GT 候选集上做 MagicLens 重排, 衡量理想候选集上的重排收益;
- E2: 在数据集给定候选上做 MagicLens 重排, 衡量局部重排能力;
- E3: 使用 CLIP 从完整 corpus 中召回 Top-5 候选, 作为真实全库检索 baseline;
- E4: LLaVA + No-RAG, 对照“不给外部证据”的情况;
- E5: GT-RAG w/o rerank, 用于检验人工标注证据条件下排序阶段的边界收益;
- E6: 使用 CLIP 粗召回后, 再由 MagicLens 对 Top-5 候选执行 rerank;
- E7: 使用 MagicLens 直接从完整 corpus 中召回 Top-5 候选, 作为 direct retrieval baseline。

- E8: Gemma 4 多维查询规划 + MagicLens 分路召回 + RRF 融合 + LLaVA 终答, 作为本文主架构;
- E9: 保持 E8 检索侧不变, 仅将终答器替换为 Gemma 4 E2B-it, 用于生成器对比。

其中, E3 是本文最重要的真实全库检索 baseline 之一。它并非只是在现成候选上调用 CLIP, 而是把 CLIP 明确放在第一阶段粗召回器的位置上。具体来说, 本文使用 openai/clip-vit-base-patch32 作为通用图文表征模型, 对完整图像语料库中的每一张图像先离线编码成向量; 测试时, 再把每个样本的输入图像 image 编码成 query embedding, 与整个 corpus 的图像向量做相似度计算, 返回 Top-5 作为检索到的候选证据图像。随后, 系统将“输入图像 + 这 5 张候选图”一起送入 LLaVA 作答。

因此, CLIP 在 E3 中扮演的是视觉粗召回器, 而不是最终回答模型或重排器。它的输入是查询图像与完整 corpus; 输出不是答案, 而是 Top-5 候选图像列表或对应相似度排序。选择 openai/clip-vit-base-patch32 的原因是该模型开放、经典、实现成熟, 推理与索引构建成本可控, 能够为 MagicLens 重排和 query rewrite 提供清晰的比较基线。实验中, 本文先对完整图像语料进行离线编码, 再在测试阶段将查询图像编码为向量, 与语料库向量计算相似度并返回排序结果。

这一点也解释了为何 MRAG-Bench 的原始评测流程不能直接得到本文的全库检索结果: 原始流程负责在既定输入图像与既定证据图像条件下调用 LLaVA 作答, 并不承担从完整图像库中召回候选的职责。CLIP 是本文为 E3、E6 等 corpus 线实验单独引入的粗召回器, 用于考察在脱离数据集 retrieved\_images 的前提下, 从完整语料库中直接检索五张证据图像时的系统行为。

### 3.4 面向多维查询与融合式终答的实验管线 (E8)

在 E0-E7 的检索对比基础上, 本文进一步将研究对象从“单路检索 + 单模型作答”推进到查询侧可扩展的多维检索与融合式多模态终答。该实验在本文中记为 E8。E8 并不是对 E0-E7 的替代, 而是在固定下游 VLM 和固定检索器参数的前提下, 对 query-side extension 的进一步探索。其目标是在不改动 MagicLens 参数的情况下, 通过多指令规划、多路 Top- $K$  结果融合、证据文本增强与 VLM, 形成一条完整的端到端流程。

#### 3.4.1 实验流程与结果记录

E8 的一条样本在系统内依次经历以下阶段:

1. **维度规划:** Gemma 4 E2B-it 读取查询图像与题干, 生成  $N$  条短英文指令; 同时输出每条维度的 rationale 作为简短生成理由, 不直接拼入检索 query。
2. **分路检索:** 对每条指令, MagicLens 在查询图像与指令条件下对外部语料各返回 Top- $K_{\text{dim}}$ 。

3. **多列表融合**: 对  $N$  路排序做倒数排名和 (RRF; 本文默认  $K_{\text{rrf}} = 60$ ) 或等价的列表融合, 得到最终 Top- $K_{\text{final}}$ 。
4. **证据描述**: Gemma 4 对“查询图 + 融合后证据图”生成简短自然语言描述, 作为 LLaVA 的辅助文本, 不改变图像序列本身。
5. **多模态终答**: 在固定多选项模板下, 将查询图与选定的融合证据图按约定顺序输入 LLaVA-OneVision 输出选项字母; 下游抽取器自输出中解析 A/B/C/D。

上述流程会保存逐样本答案、融合前后检索结果、维度层中间结果以及配套可视化图 (分维 Top-1 拼图、分维 Top- $K$  网格、查询图与融合 Top-5 拼图等), 便于在论文中分析不同维度间的重复命中、融合分数贡献与错误样本特征。

### 3.4.2 与既有实验相比的方法扩展

E8 在“查询链 + 全库多模态 RAG”意义上的方法扩展可概括为:

- **多视角指令规划**: 在查询图像与题干共同约束下生成互补检索子任务, 降低单条指令过度贴近某一外观模式导致的排序偏置。
- **多路可融合排序**: 在 MagicLens 返回的多份候选列表上引入显式融合算子, 使不同语义维度的证据能够在排序层面被折中整合。
- **推理期扩展、无需更新检索器参数**: 维数、每维 Top- $K$ 、融合策略与终答用图数均可在配置层调整, 与本文强调的 inference-time 方法路线一致。
- **VLM 下的端到端可对照**: 在 LLaVA 与提示模板的框架内, 将改进集中在检索前端的查询与融合设计, 使对比结论可解释、可复现。

### 3.4.3 样例分析: MRAG-Bench 样本 qs\_id=0

为了更具体地说明多维查询在单个样本上是如何展开的, 这里选取样本 qs\_id=0 作为示例。该样本能够体现 E8 的一个关键特点, 即系统并不把问题压缩为单一检索指令, 而是将其拆分为若干相互补充的检索目标。表 3.2 列出了该样本生成的五条检索子任务及其对应的生成依据, 用于展示系统如何从原始问题中提炼出主体识别、局部细节、背景关系和相似候选等不同方向的检索需求。

表 3.2 E8 样例 qs\_id=0: 多维度查询指令与生成理由。

| 维 | query (用于 MagicLens 检索, 与 rationale 解耦)                | rationale (生成该查询的简短理由)                                                                     |
|---|--------------------------------------------------------|--------------------------------------------------------------------------------------------|
| 1 | dog sitting on cobblestone path in front of a building | This focuses on identifying the main subject, the dog, in its environment.                 |
| 2 | black and tan dog breed identification                 | This aims to get breed-specific information about the dog's appearance.                    |
| 3 | terrier dog breeds comparison                          | This helps narrow down the options by focusing on the category of dogs presented.          |
| 4 | outdoor scene with ivy and stone pathway               | This captures the background context, which might offer clues about the location or style. |
| 5 | close-up of a small black dog                          | A close-up might reveal finer details of the dog's coat and features.                      |

多路结果经 RRF 融合后，得到长度  $K_{\text{final}} = 5$  的候选集；其倒数排名和形式为

$$\text{RRF}(d) = \sum_{j=1}^N \frac{1}{K_{\text{rrf}} + \text{rank}_j(d)}, \quad (3.1)$$

其中  $\text{rank}_j(d)$  为第  $j$  条指令对应列表中候选项  $d$  的名次，若  $d$  未出现则不计入。

仅列出检索子任务还不足以说明多维查询为何可能有效，还需要进一步看到这些子任务各自召回了什么图像、不同维度之间是否出现重复命中，以及融合后的最终证据集合与原查询图之间形成了怎样的对应关系。基于这一目的，图 3.2 将该样例展开为三类可视化结果：**(a)** 各维度 Top-1 的横向拼贴，用于观察不同维度最先命中的证据类型；**(b)** “维度  $\times$  名次”的网格总览，用于比较跨维重复命中与排序结构；**(c)** 查询图与融合后 Top-5 证据的拼图，用于展示最终送入多模态终答模型的图像条件。

在终答阶段，系统向 LLaVA 提供的文本为固定模板下的多选项问题，并附加 Gemma 4 生成的证据图描述作为辅助。下面给出生成日志中的 `prompt_question_part` 片段（英文原文；描述文本略去部分换行以节省版面）：

```
Additional visual evidence descriptions generated by Gemma4. Use them
as auxiliary evidence together with the images; answer with only
the option letter.
query_image (0.png): A small, black and tan dog is lying down ...
... (retrieved_rank_1..5 descriptions) ...
Can you identify this animal?
Choices:
A: silky_terrier
B: Yorkshire_terrier
C: Australian_terrier
D: Cairn_terrier
```

在该 5 样本子集对照实验中，`qs_id=0` 的模型预测为 B (`Yorkshire_terrier`)，标准选择为 A (`silky_terrier`)。选择这样例的原因，不是因为它取得了正确结果，而是因为它能较清楚地展示 E8 的一个典型边界：即使多维检索已经提供了较丰富的候选证据，最终判断仍可能因为细粒度类别之间的视觉歧义而失败。结合图 3.2 可以看到，当融合后的证据集合同时指向多个外观接近的犬种时，单纯增加候选数量并不足以保证最终判别正确。


#### 3.4.4 全数据集运行结果

E8 已在 `uclanlp/MRAG-Bench test split` 的 1353 条样本上完成全量运行，整体准确率为 56.32%，维度生成失败数为 0；每题均生成五条维度查询，并以 MagicLens 每维 Top-5 候选和 RRF 融合得到最终 Top-5 证据。耗时方面，单样本总耗时均值为 42.58 秒，其中维度生成 17.59 秒、MagicLens 检索与 RRF 融合 3.40 秒、Gemma 4 证据描述





(a) 分维 Top-1 拼图。



(b) 分维 Top-K 网格总览。



(c) 查询图与融合后最终 Top-5 证据拼图。

图 3.2 E8 样例 qs\_id=0 的过程性图像：维度层检索与融合层终选对照。

21.01 秒、LLaVA 终答 0.34 秒。九类场景中, E8 在 *Others* 上达到 80.00%, 在 *Scope*、*Obstruction*、*Angle* 和 *Biological* 上也分别达到 59.80%、57.41%、57.45% 和 56.86%; 相对而言, *Incomplete* 仍只有 29.41%, 说明结构补全类问题依旧是该管线最明显的薄弱点。总体来看, E8 的主要时间开销来自查询侧规划和证据描述, 而检索融合与终答本身相对轻量。

## 第4章 实验结果分析

### 4.1 本章概述

本章在第3章实验设计的基础上，对 E0–E10 相关结果进行分析。分析顺序从控制实验与总体结果开始，随后以 E8 作为本文主要架构讨论其全量效果、场景收益、候选融合结构与时间代价，再通过 E9 分析在相同检索证据下终答生成器的影响，并通过 E10 检验去掉查询重写后的单路 MagicLens 检索效果，最后回到 CLIP 与 MagicLens 的检索差异解释 E8 为什么需要多维查询和列表融合。

### 4.2 整体结果与控制实验

在进入分场景和机制分析之前，首先需要回答一个最基本的问题：各条实验线的整体表现究竟处在什么位置，哪些设置可以作为参考上界，哪些设置可以作为真实全库检索条件下的比较基线。为此，本节先从整体准确率出发，利用控制实验建立“无外部证据”“人工标注证据”和“真实全库检索”三类情形之间的相对关系，再据此确定后续重点分析对象。

从整体结果看，E4 (LLaVA+No-RAG) 的整体准确率为 **53.14%**，高于 E3 与 E7，但仍明显低于引入 GT 候选的 E0/E1/E5。这一结果表明，外部图像并不自动带来收益；当检索证据偏离问题需求时，多图输入反而可能增加下游模型的判断噪声。E5 (GT-RAG w/o rerank) 的整体准确率为 **60.16%**，与 E1 基本持平，说明在人工标注候选条件下，MagicLens 重排带来的整体收益有限；此时系统瓶颈更可能来自候选覆盖与下游多图推理，而不是单纯来自排序阶段。E8 在不使用 GT 证据的条件达到 56.32%，虽然仍低于人工标注证据条件下的参考上界，但已经显著超过 E3/E6/E7 等完整 corpus 检索路线，因此构成本文后续分析的主体。

为了把这种整体关系更直观地呈现出来，图 4.1 从两个角度组织了主要结果：左图比较 E0–E10 的总体准确率分布，帮助读者先建立全局结果排序；右图则将控制实验与 rerank 相关设置并置，进一步判断“外部证据是否真正带来收益”以及“重排是否构成主要增益来源”。从图中可以更清楚地看到，人工标注证据相关设置整体位于前列，而真实全库检索路线中只有 E8 明显突破了 E3/E6/E7，这也说明后文需要重点解释的不是单一 rerank 模块是否有效，而是 E8 为什么能够在真实检索条件下取得更稳定的提升。

### 4.3 实验命名与结果总表

在明确了整体实验格局之后，下一步需要把所有实验放回同一张总表中，统一观察不同设置在整体准确率与各类场景上的相对位置。这样做的目的，不是简单罗列数字，而是为后文的分场景分析和机制分析建立一个全局参照：读者可以先看到各实验在什么场景上更强、在什么场景上更弱，再理解这些差异为何会出现。






图 4.1 不同实验线的整体表现对比。

表 4.1 汇总了 E0-E10 的整体结果与分场景表现。为提升可读性，表中仅保留整体准确率与九类场景准确率，召回率统计改在图 4.2 中单独展示。Method 列中的颜色用于标识实验角色：**绿色加粗**表示 control 组，即无检索或人工标注证据条件下的参考设置；**红色加粗**表示完整 corpus 检索下的 baseline；**蓝色加粗**表示本文主架构及关键能力对比项。E0/E1/E5 为使用人工标注候选的 reference baseline，其数值列统一以黑色正体给出，且不参与各列最值排名。对其余各实验，数值列按大小关系标注：最大值为绿色加粗，次大值为绿色，最小值为红色加粗，倒数第二小值为红色。E8 属于本文主架构：它不依赖人工 GT 证据，但通过 Gemma 4 多维规划和 RRF 融合显著改善 E7 的 MagicLens direct retrieval。召回率统计采用统一的图像内容哈希匹配方法完成；统计时使用完整图像语料中全部可正常读取的图像，并核对各组实验返回的候选图像均可在语料库中唯一匹配。

从表中可以先得到三个直接判断。第一，E0/E1/E5 这一组基于人工标注证据的设置整体保持领先，说明在证据质量得到保证时，下游多模态模型能够稳定利用图像证据作答。第二，E3/E6/E7 三条真实全库检索路线的整体表现接近，但并未自然逼近人工标注证据条件下的水平，这再次说明真正困难的部分在于如何从完整图像库中找到有效证据。第三，E8 虽然不依赖人工 GT 证据，但在整体准确率和若干分场景指标上都明显优于 E3/E6/E7，因此它不仅是一个更高的结果点，也提供了后续分析“为什么查询侧扩展有效”的核心入口。

表 4.1 实验命名与结果总表。E8 为本文主架构，对完整 corpus 检索加入 Gemma 4 多维查询规划与 RRF 列表融合；E9 为终答生成器对比实验，E10 为查询重写消融实验。

| Method                                             | Overall | Perspective |         |       | Transformative |          |             |            | Others |       |
|----------------------------------------------------|---------|-------------|---------|-------|----------------|----------|-------------|------------|--------|-------|
|                                                    |         | Angle       | Partial | Scope | Obstruction    | Temporal | Deformation | Incomplete |        |       |
| E0: LLaVA+GT-RAG Baseline                          | 59.05   | 59.63       | 64.23   | 66.67 | 67.59          | 57.72    | 56.86       | 29.41      | 55.88  | 64.17 |
| E1: GT-RAG-RANKING <sub>magiclens</sub>            | 60.16   | 61.49       | 65.45   | 66.67 | 69.44          | 58.39    | 57.84       | 30.39      | 55.88  | 65.00 |
| E2: Retrieved-RAG-RANKING <sub>magiclens</sub>     | 51.74   | 51.24       | 50.41   | 59.80 | 59.26          | 48.99    | 55.88       | 33.33      | 50.00  | 59.17 |
| E3: CLIP-RAG Baseline (Top-5 from corpus)          | 50.41   | 52.48       | 54.07   | 48.04 | 54.63          | 46.31    | 58.82       | 22.55      | 50.00  | 57.50 |
| E4: LLaVA+No-RAG                                   | 53.14   | 56.21       | 56.10   | 55.88 | 57.41          | 47.65    | 55.88       | 33.33      | 50.98  | 55.83 |
| E5: GT-RAG-RANKING <sub>magiclens</sub> w/o rerank | 60.16   | 59.94       | 66.67   | 63.73 | 66.67          | 61.74    | 56.86       | 29.41      | 57.84  | 67.50 |
| E6: CLIP-RAG-RANKING <sub>magiclens</sub>          | 50.33   | 54.04       | 49.19   | 55.88 | 51.85          | 46.31    | 56.86       | 27.45      | 49.02  | 56.67 |
| E7: MagicLens-RAG Baseline (Top-5 from corpus)     | 47.97   | 51.55       | 47.56   | 45.10 | 48.15          | 46.98    | 50.00       | 32.35      | 50.98  | 51.67 |
| E8: Gemma4-MultiDim + MagicLens + RRF              | 56.32   | 57.45       | 54.07   | 59.80 | 57.41          | 54.36    | 54.90       | 29.41      | 25.49  | 80.00 |
| E9: E8 + Gemma4 final answerer                     | 38.95   | 44.72       | 36.99   | 30.39 | 37.04          | 41.61    | 29.41       | 26.47      | 25.49  | 63.33 |
| E10: no query rewrite                              | 53.51   | 54.66       | 50.81   | 61.76 | 56.48          | 57.72    | 53.92       | 24.51      | 57.84  | 61.67 |

仅看准确率仍然不够，因为检索增强系统中“答错”并不一定意味着检索失败，也可能是终答阶段没有充分利用已有证据。因此，这里需要再从召回率视角补上一层观察：系统究竟有没有把 GT 证据带入候选集合，尤其是多维查询是否扩大了融合前候

选池中的有效证据覆盖。

基于上述考虑，图 4.2 从证据召回率角度补充了这一层分析。与准确率不同，Recall@5 直接衡量最终进入终答阶段的 Top-5 图像是否覆盖 GT 证据；Recall@N 则进一步考察多维检索在融合之前是否已经命中过 GT。对于 E8 与 E9 这类多维查询实验，本文还额外记录候选池中的重复 GT 命中次数，用于区分收益究竟来自更高的唯一覆盖，还是来自多个维度对同一关键证据形成重复支持。结果显示，使用人工标注 GT 证据的 E0/E1/E5 均为 100%；E2 在实际进入模型的候选口径下 Recall@5 为 22.41%。相比之下，完整 corpus 单路检索的 Recall 明显偏低：E3 为 5.85%，E6 为 5.80%，E7 仅为 2.31%。E8 的最终 Recall@5 为 5.42%，但融合前候选池 Recall@N 提升到 14.13%，说明多维查询真正扩大的主要是融合前的有效证据覆盖范围，而最终 Top-5 的压缩仍会带来一定信息损失。




图 4.2 主要实验的 GT 证据召回率对比。Recall@5 表示最终 Top-5 证据对 GT 图像的覆盖比例；Recall@N 表示融合前候选池对 GT 图像的覆盖比例。

#### 4.4 Corpus 线结果分析

如果说前两节给出的还是“全局结果地图”，那么从这一节开始，分析重点将转向本文真正关心的问题：在脱离人工标注证据之后，完整图像库检索到底卡在了哪里，E8 的提升又究竟相对哪一类方法成立。为回答这个问题，本节把 E3、E6、E7 作为 corpus 线的基本参照，再将 E8 放入同一语境中比较。

E3 表明：仅使用 CLIP 从完整 corpus 中召回 Top-5 候选时，整体准确率为 50.41% (682/1353)，对应 Recall@5 为 5.85%。分场景来看，E3 在 *Deformation*、*Others* 和 *Occlusion/Obstruction* 上相对稳定，但在 *Temporal*、*Scope* 和 *Incomplete* 上明显偏弱。这说明 CLIP 能够较好保持视觉邻域，却不一定能找到对时间状态、范围判断或结构补全最有帮助的证据。

E6 对应“CLIP 粗召回 + MagicLens 重排”的混合方案，其整体准确率为 50.33%，与 E3 基本持平，Recall@5 为 5.80%。这一结果不能简单解释为 MagicLens 失效，而说明当第一阶段候选覆盖主要由视觉近邻主导时，relation-aware reranking 的收益会受

到候选集合本身的限制：如果 CLIP Top-5 中缺少真正 answer-useful evidence，重排器只能在有限候选内调整顺序。E7 评估 MagicLens 作为 direct retriever 的真实全库召回能力，其整体准确率为 47.97%，Recall@5 仅为 2.31%，略低于 E3；但其在 *Incomplete*、*Biological* 与 *Temporal* 等场景上的局部优势提示，MagicLens 的归纳偏好更接近结构补全、细粒度语义关系和时间关系，而非稳定保持实例级视觉邻域。

E8 在 E7 的基础上加入 Gemma 4 多维查询规划与 RRF 融合，整体准确率提升到 56.32%，相对 E7 提升 8.35 个百分点，相对 E3 提升 5.91 个百分点，相对 E6 提升 5.99 个百分点。分场景上，E8 的最强信号来自 *Others*，达到 80.00%，是所有 E0–E9 设置中的最高值；*Biological* 也达到 56.86%，接近使用人工标注证据的 E5 的 57.84%。从召回角度看，E8 的最终 Recall@5 为 5.42%，但融合前 Recall@N 达到 14.13%，明显高于 E7 单路直检；这说明 E8 并不是简单“多检索几次”，而是在查询规划层面将主体、属性、背景、相似候选与局部细节拆成多条可融合证据链，从而缓解 MagicLens direct retrieval 的单路偏置。

为了进一步判断这种提升是否具有明确的场景指向，而不是由少数样本偶然拉高，下面继续比较各方法在九类任务中的表现。图 4.3 采用柱状图逐类对照 E3、E6、E7，便于观察不同单路方案的局部差异；图 4.4 则把 E8 放回全部主要设置中，帮助判断它的优势主要集中在哪些任务类型。结合两图可以看出，E8 的提升并不是在所有类别上平均展开的，而是更多体现在 *Others*、*Biological* 等更依赖查询拆解与证据互补的场景上。




图 4.3 E3、E6 与 E7 在九类细分场景上的准确率柱状图。

总体来看，Corpus 线分析希望回答的核心问题是：“真实全库检索为什么难，以及 E8 为什么能比单路方法更好。”综合准确率、召回率和分场景结果，可以得到五点判断：第一，完整 corpus 检索下的粗召回误差不可忽略；第二，MagicLens 重排未能稳定改善 CLIP 的候选排序，主要受限于第一阶段候选覆盖；第三，MagicLens direct retrieval 并非整体优于 CLIP，但在少数关系性场景上具有可分析的局部优势；第四，




图 4.4 E0-E10 在九类场景上的雷达图。E8 在非 GT 全库检索路线中整体最优，并在 *Others* 与 *Biological* 等场景上体现出多维查询与 RRF 融合的优势；E9 在相同检索侧设置下仅替换 Gemma 4 终答器，整体面积明显收缩，说明终答模型的多图证据整合能力也是系统瓶颈；E10 为无查询重写的单路对照，其整体准确率介于 E7 与 E8 之间。

E8 说明通过查询侧多维规划与列表融合，可以显著改善全库检索结果；第五，仅比较 overall accuracy 不足以解释检索器价值，必须结合候选结构、跨维重复命中与失败模式一并分析。

## 4.5 CLIP 与 MagicLens 检索差异深入分析

前一节已经说明，E3 与 E7 的整体准确率差距并不大，但这并不意味着两种检索器“找到了差不多的图”。恰恰相反，如果它们走向的是两套不同的候选分布，那么 E8 为什么需要把二者的优点重新组织起来，就必须回到检索集合本身去看。基于这一考虑，本节不再从最终答题结果出发，而是直接比较 CLIP 与 MagicLens 返回的候选集合结构。

对 1353 个样本逐一比较 Top-5 候选集合后可见，MagicLens 并非在 CLIP 的语义邻域内做轻微扰动，而是在大量 query 上走向了另一套检索偏好。

### 4.5.1 检索集合差异

这里首先要看的，不是谁的准确率略高，而是两种检索器究竟在多大程度上进入了同一个视觉证据邻域。只有先回答这个问题，后面才能解释 E8 为什么不能简单地被理解为“把某个更强的检索器直接换上去”。为此，图 4.6 从重合度、首位一致率和逐样本胜负三个角度给出全局概览，用来判断 CLIP 与 MagicLens 到底是在同一批候选上竞争，还是在走两条明显不同的检索路径。






图 4.5 不同场景下错误占比或失败模式的对比示意。

在全部 1353 个样本中, CLIP 与 MagicLens 的 Top-5 候选平均仅重合 0.535 张; 909 个样本 (67.2%) 的 Top-5 候选完全没有重合, Top-5 完全一致的样本仅 1 个, Top-1 候选相同的样本也只有 204 个 (15.1%)。从答题正确率看, CLIP 正确 682 例, MagicLens 正确 649 例; 逐样本胜负统计中, CLIP 胜出 152 例, MagicLens 胜出 119 例, 两者都答对 530 例, 都答错 552 例。上述结果说明, MagicLens 的确改变了检索证据分布, 但这种改变并没有稳定转化为更高的问答准确率。

#### 4.5.2 分场景检索差异

仅有全局平均值还不够, 因为不同场景对证据类型的要求本来就不一样。若要进一步理解 CLIP 和 MagicLens 的差异来自哪里, 就需要把这种比较放回具体任务类型中, 看它们在九类场景上的重合度和胜负关系是否存在稳定模式。基于这一目的, 表 4.2 将检索集合差异拆解到各个场景中, 用来回答“哪些场景更依赖视觉近邻, 哪些场景更容易体现关系感知检索的优势”。

从 Top-5 重合度看, *Deformation* 与 *Others* 的重合度较高, 说明这两类场景下 CLIP 与 MagicLens 的检索偏好更接近; 而 *Biological*、*Partial* 与 *Scope* 三类场景重合度极低, 两者几乎检索出完全不同的候选集合。

从胜负计数看, MagicLens 的优势场景主要集中在 *Incomplete* 和 *Temporal*。其中, *Incomplete* 场景要求系统判断缺失结构或补足不可见信息, 更接近关系性与结构性推断, 而非简单视觉相似匹配; *Temporal* 场景则要求检索器捕捉状态变化和时间关系。相比之下, CLIP 在 *Partial*、*Deformation*、*Obstruction* 与 *Others* 上更稳定, 说明这些场景更依赖局部视觉近邻或外观保持。该现象支持本文对二者能力边界的判断: CLIP 更适合作为覆盖稳定的粗召回器, MagicLens 更适合在关系性检索目标明确时发挥作用。






图 4.6 CLIP 与 MagicLens 检索差异总览。

表 4.2 CLIP 与 MagicLens 在九类场景上的检索差异统计。

| 场景          | <i>n</i> | Top-5 重合 | Top-1 同 (%) | CLIP 准 (%) | ML 准 (%) | ML:CLIP 胜 |
|-------------|----------|----------|-------------|------------|----------|-----------|
| Angle       | 322      | 0.354    | 10.25       | 52.48      | 51.55    | 25:28     |
| Biological  | 102      | 0.059    | 0.00        | 50.00      | 50.98    | 6:5       |
| Deformation | 102      | 1.667    | 56.86       | 58.82      | 50.00    | 4:13      |
| Incomplete  | 102      | 0.392    | 4.90        | 22.55      | 32.35    | 17:7      |
| Obstruction | 108      | 0.306    | 8.33        | 54.63      | 48.15    | 8:15      |
| Others      | 120      | 1.500    | 61.67       | 57.50      | 51.67    | 6:13      |
| Partial     | 246      | 0.215    | 0.81        | 54.07      | 47.56    | 25:41     |
| Scope       | 102      | 0.235    | 6.86        | 48.04      | 45.10    | 10:13     |
| Temporal    | 149      | 0.698    | 10.74       | 46.31      | 46.98    | 18:17     |

注：红色表示 CLIP 与 MagicLens 候选重合度很低，蓝色表示 CLIP 更优或二者候选更接近，绿色表示 MagicLens 更优；加粗为该列需要重点关注的极值或优势项。

### 4.5.3 Top-1 高频重复偏置

在知道两种检索器会走向不同候选集合之后，还需要继续追问：MagicLens 的关系感知检索究竟是在扩大候选多样性，还是把大量查询集中吸附到少数高响应图像上。如果是后一种情况，那么它在某些场景中的局部优势就可能伴随着明显的候选集中偏置。为此，本节统计两种检索器 Top-1 候选的重复命中情况，并借助图 4.7 展示它们在头部集中度上的差异。

统计结果表明，MagicLens 存在明显的“原型图吸附”现象。CLIP 的 Top-1 候选分布较均匀，被重复命中  $\geq 5$  次的图像仅 1 张；而 MagicLens 中有 57 张图像被  $\geq 5$  个不同 query 命中为 Top-1，最高达到 39 次。图 4.7 将两种检索器的高频命中曲线放在同一坐标系下，并在右侧汇总最大重复次数、高频重复图像数、Top-10 集中度与唯一 Top-1 比例，从而更直接地展示 MagicLens 的头部集中现象。




图 4.7 CLIP 与 MagicLens 的 Top-1 高频重复命中同轴对比。曲线按各检索器自身 Top-1 命中频次降序排列，右侧指标进一步量化头部集中度与唯一候选覆盖率。

这一现象说明，MagicLens 在当前 embedding 空间中存在少数高响应“原型图”，query 表征可能被开放式指令的语义维度过度牵引，从而削弱了 query image 的实例级约束。该问题会降低检索多样性，也限制下游模型获得差异化视觉证据的能力。

## 4.6 时间代价与效率目标

到这里为止，本文已经说明 E8 在效果上优于 E3/E6/E7，但一个方法如果要具有现实意义，还需要回答另一个问题：这种收益是通过什么样的时间代价换来的，系统瓶颈究竟出现在检索侧还是生成侧。因此，本节转而考察 E8 的运行时间结构。

E8 全量过程记录显示，单样本平均总耗时为 42.58 秒，其中 Gemma 4 维度规划平均 17.59 秒，MagicLens 五路检索与 RRF 融合平均 3.40 秒，Gemma 4 对查询图和融合证据图生成描述平均 21.01 秒，LLaVA-OneVision 终答平均 0.34 秒。由此可见，E8 的性能收益主要来自查询侧规划和证据描述；真正的多路检索与融合阶段并不是瓶颈。

从部署角度看，若只保留“Gemma 4 多维规划 + MagicLens 分路召回 + RRF 融合 + LLaVA 终答”，而关闭证据描述步骤，平均耗时可显著下降。本文当前保留证据描述，是为了让日志和论文案例能够解释每张最终证据图对答题的潜在作用；在面向实际系统时，该模块可作为可解释性开关，而非必需的终答步骤。

## 4.7 扩展对比实验

前文已经围绕主实验回答了“E8 是否有效”以及“它为什么比单路检索更好”这两个核心问题。接下来需要进一步把影响因素拆开，分别判断收益究竟来自检索器、查询构造、终答生成器，还是来自中间候选组织方式。因此，本节补充扩展对比实验，对若干关键因素分别做更细的对照。

### 4.7.1 指令检索器 MagicLens 与 CLIP 的对比

虽然 E3、E6、E7 在前文已经出现，但那里的重点是它们作为 corpus 线基线时的整体表现；这里重新组织它们，是为了单独回答“CLIP 与 MagicLens 各自擅长什么”这一更聚焦的问题。具体而言，CLIP 代表基于共享嵌入空间的视觉语义近邻检索，其优势在于工程稳定、离线向量化与大规模检索成本可控；MagicLens 则代表 instruction-conditioned relation retrieval，更强调查询图像与开放式文本指令共同约束下的关系感知检索。前者更适合回答“能否先保住视觉邻域”的问题，后者更适合回答“能否进一步逼近当前问题真正需要的证据图像”的问题。

在实验组织上，本小节主要比较三种设置：其一，使用 CLIP 从完整语料库中直接召回 Top- $K$  候选，并送入固定下游视觉语言模型完成作答；其二，先由 CLIP 提供粗召回，再由 MagicLens 对候选列表执行关系感知重排；其三，直接使用 MagicLens 从完整语料库中返回 Top- $K$  候选。三种设置共同构成从“视觉近邻优先”到“关系约束优先”的能力谱系，有助于分析当前系统在不同检索归纳偏好下的行为差异。

本小节的评价不只关注最终多选题准确率，还特别关注召回集合的结构差异，包括 Top- $K$  overlap、Top-1 match rate、逐样本胜负统计与高频重复命中分布等指标。前者用于刻画不同检索器是否进入同一视觉证据邻域，后者用于判断不同检索器是否存在共享的“共识中心”或相反的显著偏离。当两种检索器在最终准确率上接近而候选集合差异很大时，意味着二者可能通过不同的检索路径抵达相近的终答表现；反之，若检索集合较为接近但最终准确率差异明显，则说明下游模型对候选排序或首位证据更为敏感。

为了把这一点说得更清楚，表 4.3 从检索器设置角度重新组织了 E3、E6、E7 与 E8。这里的重点不是重复列出主实验结果，而是把“仅替换检索器”和“同时改变查

询构造与融合方式”这两类变化明确区分开。由此可以看出，单独更换检索器并不足以解决完整 corpus 检索问题，而 E8 的收益来自“查询构造 + 多路召回 + 融合”这一组合。

表 4.3 MagicLens、CLIP 与 E8 查询侧扩展的对比结果。

| 方法设置                            | 整体准确率 | 分场景准确率                              | 平均每样本时间 | 备注                 |
|---------------------------------|-------|-------------------------------------|---------|--------------------|
| CLIP direct retrieval (E3)      | 50.41 | Deformation 58.82 / Others 57.50    | 未统一统计   | 视觉语义粗召回            |
| CLIP + MagicLens rerank (E6)    | 50.33 | Deformation 56.86 / Others 56.67    | 未统一统计   | 混合检索，受 CLIP 候选覆盖限制 |
| MagicLens direct retrieval (E7) | 47.97 | Incomplete 32.35 / Biological 50.98 | 未统一统计   | 指令关系检索，但存在单路偏置     |
| Gemma4 + MagicLens + RRF (E8)   | 56.32 | Others 80.00 / Biological 56.86     | 42.58s  | 本文主架构，多维查询与列表融合    |

#### 4.7.2 下游生成器 LLaVA 与 Gemma 4 的对比

在明确了检索器与查询构造的作用之后，还需要进一步排除另一种可能：E8 的优势是否主要来自终答生成器本身，而非检索侧改进。为此，本小节固定 E8 的检索侧结构，仅替换最终答题器，专门观察同一组检索证据在不同 VLM 下的利用差异。

为尽量将性能变化归因于检索器与查询构造环节，本文前述 E0-E8 主实验统一采用 LLaVA-OneVision 作为终答生成器，而将 Gemma 4 主要用于维度规划、查询重写与证据描述。这一设置的优点是变量控制清楚，能够避免“检索器变化”与“生成器变化”同时发生，从而使主实验更容易解释。与此同时，本文在系统实现层面已经为 Gemma 4 直接承担终答生成任务预留接口，因此 E9 将 E8 的最终答题器由 LLaVA-OneVision 替换为 Gemma 4 E2B-it，用于观察同一类检索证据在不同 VLM 终答器下的利用差异。

E9 保持 E8 的检索侧主架构不变：Gemma 4 仍负责生成五条多维检索 query，MagicLens 仍对每一维执行 full corpus Top-5 检索，RRF 仍融合得到最终 Top-5 证据，Gemma 4 仍生成查询图与证据图的辅助描述；唯一主要变量是最终多选题答题器。全量 1353 个样本上，E9 的 overall accuracy 为 38.95% (527/1353)，明显低于 E8 的 56.32% (762/1353)，下降 17.37 个百分点。E9 的最终答题阶段没有运行异常，选项抽取失败仅 4 题 (0.30%)，因此性能下降不能主要归因于格式错误，而应归因于 Gemma 4 E2B-it 在当前多图证据组织方式下的判别与证据整合能力不足。

分场景看，E9 仍在 *Others* 上取得最高值 63.33%，但相比 E8 的 80.00% 下降 16.67 个百分点；*Angle* 与 *Temporal* 分别为 44.72% 和 41.61%，是相对较稳的两类；下降最明显的是 *Biological*、*Scope* 与 *Deformation*，分别只有 25.49%、30.39% 和 29.41%。逐样本对照进一步显示，E8 与 E9 同时答对 376 题，E8 对而 E9 错 386 题，E8 错而 E9 对 151 题，两者同时答错 440 题。这说明 Gemma 4 并非完全不能利用检索证据，但其收益不足以抵消大量 E8 正确样本上的退化。

表 4.4 LLaVA 与 Gemma 4 终答生成器对比结果。

| 终答生成器           | 检索设置                               | 整体准确率 | 平均终答耗时 | 终答失败率          |
|-----------------|------------------------------------|-------|--------|----------------|
| LLaVA-OneVision | E8: Gemma 4 多维查询 + MagicLens + RRF | 56.32 | 0.34s  | 0.00%          |
| Gemma 4 E2B-it  | E9: 同 E8 检索侧，仅替换终答器                | 38.95 | 1.46s  | 0.30% (选项抽取失败) |

### 4.7.3 RRF 融合与候选结构

E8 的提升不仅来自“多检索几次”，还来自“怎样把多路检索结果组织成一个最终候选集合”。因此，本小节进一步关注融合阶段本身：RRF 到底改变了什么样的候选结构，它是单纯扩大了候选池，还是让不同维度对同一关键证据形成了更稳定的支持。

在 E8 中，查询侧扩展并不是到多路召回为止，后续如何把这些结果组织成最终证据集合，同样决定了系统最后看到的视觉条件。本文当前全量结果采用 RRF 作为默认融合策略。统计结果显示，E8 的整体准确率为 56.32%，融合前候选池平均包含 25 个输入候选、约 19.35 个唯一候选，唯一候选比例为 77.40%；同时 94.75% 的样本存在跨维重复命中。这说明 RRF 的作用并不是简单扩大候选数量，而是在保留一定多样性的同时，使多个维度能够对同一候选形成共识，从而重塑最终的候选结构。

### 4.7.4 检索结果可视化与案例展示

数值统计能够告诉我们“结果如何”，但很难直接说明“系统究竟看到了什么图、这些图之间是什么关系”。因此，在讨论候选结构之后，还需要通过可视化结果把检索阶段的中间状态直观呈现出来，使前面的统计判断能够回到具体样本上得到验证。E8 可以输出各维度 Top-1 横向拼贴、分维 Top-K 网格总览、查询图与融合后 Top-5 证据拼图等可视化结果。这些图像用于观察不同维度间是否重复命中相同候选、判断融合前后证据多样性是否提升，以及对照错误案例分析模型实际接收到的视觉条件。

本小节展示 E8 已生成的代表性过程图。对于正确样本，重点展示多维查询是否确实召回了互补证据；对于错误样本，重点展示失败是源于候选图像偏离任务需求、候选之间高度冗余，还是下游模型未能利用已有证据；对于边界样本，则重点展示“检索阶段已经逼近正确视觉邻域，但最终选择仍然失败”的情况，以区分检索瓶颈与生成瓶颈。与“维度  $\times$  Top-K”网格相关的可视化已在第 3.4.3 节的图 3.2(b) 中给出，因此本节不再重复展示同一图像。结合该图可以看到，不同维度之间既存在对同一候选的重复命中，也保留了部分互补候选，这正是后续 RRF 融合能够形成跨维共识而非简单拼接列表的基础。

## 4.8 消融实验

前文的主实验已经说明 E8 整体上优于单路检索方案，但要把这个结论讲完整，还需要继续追问：究竟是哪一个具体模块在起作用，多维查询的收益是否真的来自查询重写本身，而不是其他伴随变化。基于这一目的，本节通过消融实验把 E8 中最关键的查询构造因素单独拿出来分析。

对于本文这样的 inference-time 系统工作而言，消融实验的意义尤其重要：由于本文不进行检索器再训练，因此所有性能变化都来自查询构造、候选组织、融合方式和终答输入策略等推理期组件。当前正文只纳入已经完成全量运行并完成召回统计的消融项，即 E10 查询重写消融，以及由 E8/E10 对照得到的单维与多维查询差异。

### 4.8.1 查询重写模块的作用分析

首先需要验证的是，E8 的收益究竟是不是来自查询重写。本文在查询链中引入查询重写模块，目的不是把原始问题改写得更好，而是把其从“更接近生成任务的语言形式”转换为“更接近图像检索需求的中间表示”。在 vision-centric mRAG 中，原始问题往往包含较强的任务导向表达，但不一定直接指出应检索的视觉证据类型。查询重写尝试补足这一缺口，通过关键词抽取、关系补全和中间语义展开，把问题映射为更适合 MagicLens 或其他检索器消费的 query 表达。

本小节的消融方式是：保持检索器、候选库、下游生成器和最终融合策略不变，仅比较“直接使用原始问题文本”与“先进行查询重写后再检索”两种设置。E10 直接把原始 question 与 choices 作为单条 MagicLens 检索指令，E8 则由 Gemma 4 生成五条互补检索维度并进行 RRF 融合。结果显示，E10 的整体准确率为 53.51%，低于 E8 的 56.32%；E10 的 Recall@5/Recall@N 均为 5.00%，而 E8 虽然最终 Recall@5 只有 5.42%，但融合前 Recall@N 达到 14.13%。这说明多维查询重写的主要贡献不是让最终 Top-5 直接覆盖更多 GT，而是显著扩大融合前候选池中的有效证据覆盖，为后续融合和终答提供更大的证据空间。

**表 4.5** 查询重写模块消融结果。E10 直接使用原始问题与选项作为单条检索指令，E8 使用 Gemma 4 生成五条互补查询并进行 RRF 融合。

| 设置            | 整体准确率 | R@5  | R@N   | 平均检索耗时 | 备注                 |
|---------------|-------|------|-------|--------|--------------------|
| 不使用查询重写 (E10) | 53.51 | 5.00 | 5.00  | 0.71s  | 原始问题直接检索           |
| 使用多维查询重写 (E8) | 56.32 | 5.42 | 14.13 | 3.40s  | Gemma 4 五维查询 + RRF |

### 4.8.2 多维查询相较单维查询的收益分析

在确认查询重写本身有效之后，还需要进一步回答另一个更细的问题：E8 的提升究竟来自“改写得更好”，还是来自“维度数量变多、证据来源变得互补”。因此，本小节继续比较单维查询与多维查询两种设置，重点观察多维结构本身是否带来了候选覆盖上的实质变化。

E8 的核心出发点之一，是单一检索指令难以同时覆盖实例识别、关系补全、背景约束和细粒度判别等多种需求。因此，本文引入多维查询，通过多个互补子任务共同构造最终候选集合。尽管从方法直觉上看，多维查询应优于单维查询，但这一收益并非无条件成立：若不同维度之间高度重叠，则只是把同一语义重复表达；若各维度约束彼此冲突，则可能稀释候选质量。

本小节通过比较单维查询与多维查询两种设置来分析这一问题。单维查询采用 E10 的原始问题直接检索，多维查询采用 E8 的五维查询与 RRF 融合。分析重点不只是看整体准确率是否提升，还要看不同维度是否真的提供了互补证据。E8 的融合前候选池平均包含 25 个输入候选、约 19.35 个唯一候选，唯一候选比例为 77.40%；同时 94.75% 的样本存在跨维重复命中，说明多维查询并非简单制造完全分散的候选，而是在保留多样性的同时形成一定证据共识。

表 4.6 单维查询与多维查询比较结果。

| 设置         | 整体准确率 | R@5  | R@N   | 候选结构             | 备注         |
|------------|-------|------|-------|------------------|------------|
| 单维查询 (E10) | 53.51 | 5.00 | 5.00  | 单路 Top-5         | 原始问题直接检索   |
| 多维查询 (E8)  | 56.32 | 5.42 | 14.13 | 25 输入 / 19.35 唯一 | 五维查询 + RRF |



## 第5章 总结

### 5.1 总结

本文围绕 vision-centric mRAG 中“系统究竟应当检索什么样的视觉证据”这一核心问题展开研究。与将检索简单理解为寻找视觉上最相似图像的思路不同，本文强调，多模态问答中的关键不只是找到“像”的图像，而是找到能够真正支撑回答的问题相关证据。基于这一判断，本文从问题导向证据检索的角度重新审视 MRAG-Bench，指出 benchmark 自带候选与人工标注证据之间存在明显覆盖缺口，从而说明 vision-centric mRAG 的瓶颈并不只是后续生成模型如何作答，更在于检索阶段能否把正确证据带到模型面前。

在此基础上，本文创新性地提出了面向问题导向证据召回的混合检索思路：以 CLIP 提供稳定的视觉邻域召回，以 MagicLens 补充关系感知能力，并进一步通过多维查询生成与结果融合增强复杂问题下的证据搜索能力。实验结果表明，单纯依赖局部重排或单一路径检索都难以稳定解决 vision-centric mRAG 中的证据缺失问题，而将候选覆盖、关系建模与查询表达协同起来，能够更有效地提升非 GT 条件下的检索表现。更重要的是，本文不仅比较了不同方法“谁更好”，还进一步揭示了它们“为什么会成功或失败”，从而把研究重点从结果优劣推进到机制理解。

从更广泛的意义上看，vision-centric mRAG 的价值并不只在于提高若干基准上的问答准确率，更在于推动多模态系统从“依赖参数记忆作答”走向“依赖外部证据作答”。本文的工作表明，只有当检索目标真正从“相似图像”转向“有效证据”时，多模态检索增强生成系统才可能获得更强的可解释性、可验证性与实际应用价值。

### 参考文献

- [1] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakub Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. *arXiv preprint arXiv:1706.03762*, 2017.
- [2] Shervin Minaee, Tomas Mikolov, Narjes Nikzad, Meysam Chenaghlu, Richard Socher, Xavier Amatriain, and Jianfeng Gao. Large language models: A survey. *arXiv preprint arXiv:2402.06196*, 2024.
- [3] Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Yennie Yih, Tim Rocktäschel, Sebastian Riedel, and Douwe Kiela. Retrieval-augmented generation for knowledge-intensive nlp tasks. 33:9459–9474, 2020.
- [4] Yunfan Gao, Y. Li, D. Zhao, and H. Su. Retrieval-augmented generation for large

- language models: A survey. *arXiv preprint arXiv:2312.10997*, 2023.
- [5] L. Mei et al. A survey of multimodal retrieval-augmented generation. *arXiv preprint arXiv:2504.08748*, 2025.
  - [6] M.M. Abootorabi et al. Ask in any modality: A comprehensive survey on multimodal retrieval-augmented generation. *arXiv preprint arXiv:2502.08826*, 2025.
  - [7] Y. Li, Y. Du, L. Zhou, S. Huang, et al. Evaluating object hallucination in large vision-language models. In *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, pages 313–331, 2023.
  - [8] Lei Wang, Chen Ma, Xinuo Feng, Xingyu Su, Ruochen Zhang, Roy Xu, Yufeng Niu, Shan An, et al. A survey on large language model based autonomous agents. *arXiv preprint arXiv:2308.11432*, 2023.
  - [9] Anthropic. Introducing the model context protocol. 2024.
  - [10] Anthropic. Claude code: Anthropic’s ai-powered coding assistant. 2024.
  - [11] LangChain. Langchain state of ai agents report. 2024.
  - [12] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, et al. Learning transferable visual models from natural language supervision. In *International Conference on Machine Learning*, pages 8748–8763, 2021.
  - [13] K. Zhang et al. Magiclens: Self-supervised image retrieval with open-ended instructions. *arXiv preprint arXiv:2403.19651*, 2024.
  - [14] T. Xie, W. Li, and et al. Wang, Y. Embodied-rag: General non-parametric embodied memory for retrieval and generation. *arXiv preprint arXiv:2409.18313*, 2024.
  - [15] A. Caria et al. Towards predictive communication: The fusion of large language models and brain–computer interface. *Sensors*, 25(13):3987, 2025.
  - [16] Yuxiao Zhao, Guohua Dong, Lei Zhu, and Xiaomin Ying. Memory recall: Retrieval-augmented mind reconstruction for brain decoding. *Information Fusion*, 123:103280, 2025.
  - [17] Research Team. Genesis: A generative model of episodic-semantic interaction. *arXiv preprint arXiv:2510.15828*, 2025.
  - [18] W. Hu et al. Mrag-bench: Vision-centric evaluation for retrieval-augmented multimodal models. *arXiv preprint arXiv:2410.08182*, 2024.

- [19] Aidan Gomez et al. Align: Scaling up visual and vision-language representation learning with noisy text supervision. *Google Research Blog*, 2021.
- [20] C. Xie et al. Fg-clip: Fine-grained visual and textual alignment. *arXiv preprint arXiv:2505.05071*, 2025.
- [21] Beichen Zhang, Pan Zhang, Xiaoyi Dong, Yuhang Zang, and Jiaqi Wang. Long-clip: Unlocking the long-text capability of clip. *arXiv preprint arXiv:2403.15378*, 2024.
- [22] H. Ma et al. Ei-clip: Entity-aware interventional contrastive learning for e-commerce cross-modal retrieval. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 21991–22000, 2022.
- [23] Alex Nichol, Prafulla Dhariwal, Aditya Ramesh, Pranav Shyam, Pamela Mishkin, Bob McGrew, Ilya Sutskever, and Mark Chen. Glide: Towards photorealistic image generation and editing with text-guided diffusion models. *arXiv preprint arXiv:2112.10741*, 2022.
- [24] Robin Rombach, Andreas Blattmann, Dominik Lorenz, Patrick Esser, and Björn Ommer. High-resolution image synthesis with latent diffusion models. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 10684–10695, 2022.
- [25] Xi Chen et al. Pali: A jointly-scaled multilingual language-image model. *arXiv preprint arXiv:2209.06794*, 2022.
- [26] Lvmin Zhang and Maneesh Agrawala. Adding conditional control to text-to-image diffusion models. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 3836–3847, 2023.
- [27] Y. Tian et al. Stablerep: Synthetic images from text-to-image models for visual representation learning. *arXiv preprint arXiv:2306.00984*, 2023.

## 致 谢

本文从选题、实验设计、代码实现到论文整理，得到了导师宋歌老师的耐心指导和持续帮助。在研究推进过程中，老师不仅在研究方向和论文结构上给予了明确建议，也在实验组织、问题拆分和结果分析方面提供了很多启发，使我能够逐步把零散的实验记录整理为较完整的研究主线。在此谨向宋老师表示诚挚的感谢。

同时，感谢实验室和项目协作过程中给予帮助的同学与朋友。大家在数据处理、模型运行、图表讨论和论文修改中的交流，使我在面对复杂问题时能够不断修正思路、保持推进。也感谢学院在本科阶段提供的课程训练与科研实践机会，使我能够逐步完成从课程学习到研究实践的过渡。

最后，感谢家人在本科阶段给予的理解、支持与鼓励。正是因为这些帮助，我才能够持续投入到本课题的学习、实验与写作之中，并完成本文工作。

## 本科期间主要研究成果

### 发表论文

1. **Ziyan Shi**, Y Gu, H Cui, et al. From Machine Learning to Multimodal Models: The AI Revolution in Enzyme Engineering. *BioDesign Research*, 2025. DOI: 10.1016/j.bidere.2025.100044. (SCI, 影响因子 4.7, JCR Q1)
2. Yuan S, Peng N, **Shi Z**, et al. Detection of algal tiny objects based on morphological features. *Concurrency and Computation: Practice and Experience*, 2024:e8128. DOI: 10.1002/cpe.8128. (SCI/SCIE, 中科院 4 区, JCR Q2)
3. S. Yuan, N. Peng, Z. **Shi**, Y. Gu and B. Sun. "MAgic: A Morphable Attention Based Algal Tiny Object Detection Model," in *2023 10th International Conference on Behavioural and Social Computing (BESC)*, Larnaca, Cyprus, 2023, pp. 1–8. DOI: 10.1109/BESC59560.2023.10386562. (EI, IEEE)

### 完成项目

1. 参与基于 YOLOv8 的藻类微小目标检测研究，围绕形态学特征建模、注意力机制设计与数据集构建开展实验，形成 conference 与 journal 两条成果线。
2. 参与酶工程方向的 AI for Science 研究，围绕酶功能预测、酶工程任务建模与多模态模型在生命科学中的应用开展文献调研与综述写作，形成 *BioDesign Research* 论文成果。
3. 参与酶学编号预测 (EC number prediction) 相关项目，面向分子表示、反应式建模与酶功能分类问题进行数据处理、模型实验与结果分析。
4. 参与实验室自动化方向项目，基于 Opentrons 平台完成实验流程编排与自动化脚本编写，支持 PCR 等湿实验步骤的标准化执行。
5. 参与脑启发计算方向项目，围绕 BrainPy 建模、神经形态计算平台使用与相关学术交流活动开展学习与实践。
6. 参与基于 THz 的脑机接口 (BCI) 方向项目，围绕多模态信号整合、设备方案设计与算法分析开展前期研究与实验探索。
7. 参与 iGEM Competition 与 iGEM Hackathon 相关项目，完成队伍协作、方案设计与竞赛实践。